⬡ CEMENTOS ARGOS · PROYECTO DIGITAL

Documentación Técnica v1.0

Censo Digital de Ferreterías Colombia

Sistema automatizado de recolección, enriquecimiento y visualización del universo ferretero colombiano

📅 Abril 2026 📦 48.237 registros 🔧 n8n + Supabase + FastAPI 🤖 Groq IA (llama-3.1-8b)

1 VISIÓN GENERAL DEL PROYECTO

Construir un sistema automatizado que levante, enriquezca y visualice el **censo digital de ferreterías en Colombia** para Cementos Argos, permitiendo identificar clientes potenciales para el canal de distribución de cemento.

2 FLUJO DE LA SOLUCIÓN

FASE 1
Recolección
CSV Cámaras de Comercio
48.237 registros

▶

FASE 2
Almacenamiento
Supabase
PostgreSQL en la nube

▶

FASE 3
Enriquecimiento
Google Maps + Portafolio.co +
Groq IA

▶

FASE 4
Exportación
Google Sheets
para análisis comercial

▶

FASE 5
Visualización
Dashboard web
+ Agente IA

3 TECNOLOGÍAS Y HERRAMIENTAS

HERRAMIENTA	ROL	COSTO
n8n (self-hosted, Docker)	Orquestador de workflows	Gratis
Supabase	Base de datos PostgreSQL en la nube	Gratis (tier free)
FastAPI + Python	API de consulta y dashboard web	Gratis
Docker Desktop	Contenedores locales	Gratis
Google Maps Places API	Geocodificación (coordenadas, dirección)	$0.032 / req
Groq API (llama-3.1-8b-instant)	Extracción de ubicación + fallback scraping	Gratis
Google Sheets API	Exportación de datos enriquecidos	Gratis

HERRAMIENTAS DE PAGO QUE MEJORARÍAN EL PROCESO

HERRAMIENTA	VENTAJA SOBRE LA SOLUCIÓN ACTUAL	COSTO ESTIMADO
Informatica MDM	Gestión de datos maestros, deduplicación avanzada	$50.000+/año
Melissa Data	Limpieza y normalización profesional de contactos	$300–500/mes
ZoomInfo	Enriquecimiento con datos financieros y contactos	$10.000+/año
Talend Data Quality	Plataforma completa de calidad de datos	$500+/mes
Google Maps Platform (escala)	Sin límites de rate, SLA garantizado	~$1.536 para 48k
n8n Cloud	Sin servidor local, alta disponibilidad	$20/mes
Supabase Pro	Más almacenamiento, backups automáticos	$25/mes

4 ESTRUCTURA DEL DATASET

CAMPO	TIPO	EJEMPLO
razon_social	texto	FERRETERÍA EL CONSTRUCTOR S.A.S
nit	texto	900123456-1
camara_comercio	texto	MEDELLIN PARA ANTIOQUIA
representante_legal	texto	GARCÍA LÓPEZ CARLOS MARIO
organizacion_juridica	texto	Sociedad por Acciones Simplificada
estado_matricula	texto	ACTIVA
fecha_matricula	fecha	2015-03-12
fecha_renovacion	fecha	2024-01-08
direccion	texto	Cra. 50 #32-18, El Poblado
ciudad	texto	Medellín
departamento	texto	Antioquia
telefono	texto	3104567890
email	texto	ferreteria@correo.com
lat / lng	decimal	6.2087 / -75.5659
formatted_address	texto	Cra. 50 #32-18, El Poblado, Medellín, Antioquia
estado_info	calculado	Completa / Incompleta
estado_legal	calculado	Legalmente constituida

CAMPO	TIPO	EJEMPLO
geocodificado	booleano	true / false
num_fuentes	entero	1 / 2 / 3

5 PROBLEMAS Y SOLUCIONES ENCONTRADOS

PROBLEMA	HERRAMIENTA	SOLUCIÓN APLICADA
Docker no corría con WSL2	Docker Desktop	Cambio a backend Hyper-V vía BIOS
`process.env` no disponible en Code nodes	n8n 2.14	Reemplazado por `$env`
OpenAI sin crédito disponible (error 429)	OpenAI API	Reemplazado con Groq (gratuito)
Error 400 en filtro `lat=not.is.null`	Supabase REST	Filtro aplicado en JavaScript post-query
Google Maps devuelve direcciones de otros países	Google Maps API	Validación posterior con Groq IA
Esquema de herramienta incompatible con Groq	n8n + Groq	Cambio de GET query params a POST JSON body
Workflows se desactivan al reiniciar Docker	n8n	Reactivación manual tras cada restart
Contenedores bloqueados sin poder detenerse	Docker Desktop	Restart completo de Docker Desktop
Google Sheets requiere columna match en "Append or Update"	Sheets + n8n	Cambio a operación simple "Append Row"
Parsing incorrecto de ciudad/departamento	Procesamiento texto	Reemplazado con modelo IA Groq
AI Agent inventa nombres de herramientas (hallucination)	n8n + Groq	Reemplazado por HTTP Request directo a Groq API
`splitInBatches` con loop-back genera bucle infinito	n8n	Eliminado; lógica movida a `for` loop en Code node
Mismo teléfono repetido para todas las empresas	portafolio.co	CSS Selector específico: `<span itemprop="telephone">`
portafolio.co bloquea con CAPTCHA ante múltiples peticiones	Web scraping	Detección de CAPTCHA + timeout `Promise.race` 3s

6 WORKFLOWS DE N8N

ARCHIVO	FUNCIÓN
`00_orquestador.json`	Recibe peticiones del dashboard y enruta a cada sub-workflow
`04_sub_agente_ia.json`	Agente conversacional con contexto de las ferreterías
`05_sub_carga_csv.json`	Lee y carga el CSV de cámaras de comercio a Supabase
`06_sub_enriquecimiento_maps.json`	Busca coordenadas en Google Maps para cada ferretería
`07_sub_exportar_sheets.json`	Exporta todos los datos a Google Sheets
`08 - Sub_ Web Scraping Portafolio.json`	Scraping de teléfono/email desde portafolio.co con Groq IA fallback

7 MÓDULO 08 — WEB SCRAPING PORTAFOLIO.CO

Enriquecer los registros que no tienen teléfono o email buscando esa información en **empresas.portafolio.co**. Usa CSS selector como método principal y Groq IA como fallback inteligente.

> **Nota sobre automatización:** El proceso es manual durante la fase de preparación y corrección de errores. Una vez estabilizado, se migrará a ejecución automatizada programada.

FLUJO DEL WORKFLOW

```
Trigger └→ Obtener Sin Teléfono/Email ← Supabase: or=(telefono.is.null, email.is.null), paginado 500 └→ ¿Terminó? ├─ true → Resumen Final └─ false → Scraping y Guardar ← for loop interno sobre todos los registros └→ ¿Continuar? ├─ true → Obtener Sin Teléfono/Email (siguiente lote de 500) └─ false → Resumen Final
```

LÓGICA INTERNA: SCRAPING Y GUARDAR

A

CONSTRUCCIÓN DE URL (TOSLUG)

Convierte `razon_social` a slug para armar la URL:
`FERRETERIA EL PERNO SAS` → `FERRETERIA-PERNO-SAS`

Palabras ignoradas: Y, DE, DEL, LA, LAS, LOS, EL, EN, A, E, CON, POR, PARA, SU, AL, UN, UNA
La palabra NO se conserva (aparece en muchos nombres)

B

FETCH CON TIMEOUT GARANTIZADO

Usa `Promise.race()` entre la solicitud HTTP y un timer de **3 segundos**. Si portafolio.co no responde a tiempo → pasa al siguiente sin bloquear.

Detecta CAPTCHA (*"Demasiadas peticiones"*) y lo trata como sin respuesta.

C

CSS SELECTOR (MÉTODO PRINCIPAL)

Busca directamente en el HTML usando el estándar Schema.org:

```
<span itemprop="telephone">3172623722</span>
<span itemprop="email">x@empresa.co</span>
```

D

GROQ IA FALLBACK

Se activa solo si CSS no encontró datos pero hay HTML:

Modelo: `llama-3.1-8b-instant`
Envía 2000 chars del HTML (sección `listData`)
Respuesta: `{"telefono": "...", "email": null}`

E

GUARDAR EN SUPABASE

Solo hace PATCH cuando hay datos nuevos: `{ "telefono": "3172623722", "num_fuentes": 3 }`
Si no encuentra nada → el registro queda con `null` y el contador no cambia. Pausa de **1 segundo** entre empresas.

CONTADOR NUM_FUENTES

1	2	3
Solo CSV inicial (cámara de comercio)	CSV + Google Maps encontró coordenadas	CSV + Maps + Portafolio encontró teléfono/email

LIMITACIONES CONOCIDAS

🔒 **CAPTCHA**
portafolio.co bloquea peticiones frecuentes. El workflow lo detecta y continúa sin error.

🔍 **Cobertura parcial**
No todas las empresas tienen ficha en portafolio.co. Las que no tienen quedan con null.

📧 **Email escaso**
portafolio.co raramente publica emails. En la mayoría de casos solo se obtiene teléfono.

⏱️ **Velocidad**
Máximo 4 seg/empresa (3s timeout + 1s pausa). Para 48.000 empresas: ~53 horas en ejecución continua. Se recomienda ejecutar por lotes.

VARIABLES DE ENTORNO REQUERIDAS

```
SUPABASE_URL=https://xxxx.supabase.co SUPABASE_SERVICE_KEY=eyJ... GROQ_API_KEY=gsk_...
```

SQL EN SUPABASE (EJECUTAR UNA SOLA VEZ)

```
ALTER TABLE ferreterias ADD COLUMN IF NOT EXISTS num_fuentes INTEGER DEFAULT 1;
```